

第4章 非线性规划

无约束最优化方法



无约束最优化方法

- 求解n元函数的无约束最优化问题（UMP）

$$\min f(x)$$

其中 $x = (x_1, \dots, x_n)^T \in \mathbf{R}^n, f: \mathbf{R}^n \mapsto \mathbf{R}$ 。

1. 无约束最优化问题的最优性条件
2. 最速下降法
3. 共轭方向法

UMP问题的最优性条件

下降方向

定理 4.4.1 设 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 在点 $\bar{x} \in \mathbb{R}^n$ 处可微。若存在 $p \in \mathbb{R}^n$ ，使得 $\nabla f(\bar{x})^\top p < 0$ ，则向量 p 是 f 在点 \bar{x} 处的下降方向。

向量内积

● 证：因为 f 在 \bar{x} 处可微，由 f 在 \bar{x} 处的 Taylor 展开式，对任意的 $t > 0$ ，有：

$$f(\bar{x} + tp) = f(\bar{x}) + t \nabla f(\bar{x})^\top p + o(\|tp\|)。$$

- 由于 $\nabla f(\bar{x})^\top p < 0$ ， $t > 0$ ，可知 $t \nabla f(\bar{x})^\top p < 0$ 。
- 因此， $\exists \delta > 0$ ， $\forall t \in (0, \delta)$ ，有 $t \nabla f(\bar{x})^\top p + o(\|tp\|) < 0$ 。
- 即， $\forall t \in (0, \delta)$ ， $f(\bar{x} + tp) < f(\bar{x})$ 。可知 p 是 f 在 \bar{x} 处的下降方向（定义 4.1.3）。

下降方向

- 说明：证 $\exists \delta > 0$, $\forall t \in (0, \delta)$, 有 $t \nabla f(\bar{x})^\top p + o(\|tp\|) < 0$ 。 (1)
- 若 $o(\|tp\|) \leq 0$, 则(1)已经成立。下面假设 $o(\|tp\|) > 0$ 。
- 只需证 $\exists \delta > 0$, $\forall t \in (0, \delta)$, $\frac{o(\|tp\|)}{t} < -\nabla f(\bar{x})^\top p$ 。 (2)
- 由定理 4.2.3 的证明, 可知 $\lim_{t \rightarrow 0} \frac{o(\|tp\|)}{t} = 0$ 。
- 由函数极限的定义, 自然有(2)成立。

附：函数极限的定义

- 设 $y = f(x)$ 在点 x_0 的某个去心邻域内有定义，即存在 $\rho > 0$ ，使得 $O(x_0, \rho) \setminus \{x_0\} \subset D_f$ 。
- 如果存在实数 A ，对于任意给定的 $\varepsilon > 0$ ，可以找到 $\delta > 0$ ，使得当 $0 < |x - x_0| < \delta$ 时，成立 $|f(x) - A| < \varepsilon$ ，则称 A 是函数 $f(x)$ 在点 x_0 处的极限，记为 $\lim_{x \rightarrow x_0} f(x) = A$ 。
- 如果不存在具有上述性质的实数 A ，则称函数 $f(x)$ 在点 x_0 处的极限不存在。

局部最优解的必要条件

定理 4.4.2 设 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 在点 $\bar{x} \in \mathbb{R}^n$ 处可微。若 x^* 是(UMP)的局部最优解, 则 $\nabla f(x^*) = 0$ 。注意是必要条件, 非充分条件

● 证: 因为 x^* 是局部最优解, 由定义, $\exists \delta > 0$,

$$\forall x \in N_\delta(x^*), \text{ 有 } f(x^*) \leq f(x). \quad (1)$$

● 反证。假设 $\nabla f(x^*)^T = \left(\frac{\partial f(x^*)}{\partial x_1}, \frac{\partial f(x^*)}{\partial x_2}, \dots, \frac{\partial f(x^*)}{\partial x_n} \right) \neq 0$ 。不妨

$$\text{设 } \frac{\partial f(x^*)}{\partial x_1} \neq 0。$$

● 令 $p^T = \left(-\frac{\partial f(x^*)}{\partial x_1}, 0, \dots, 0 \right)$ 。则 $\nabla f(x^*)^T p < 0$ 。

局部最优解的必要条件

- 由定理 4.4.1, 可知 $\exists \delta' > 0$, $\forall t \in (0, \delta')$, 有 $f(x^* + tp) < f(x^*)$ 。
- 取 t 充分小, 可使 $x^* + tp \in N_\delta(x^*)$, 与(1)矛盾。

局部最优解的充分条件

定理 4.4.3 设 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 在点 $\bar{x} \in \mathbb{R}^n$ 处的 Hesse 矩阵 $\nabla^2 f(x^*)$ 存在。若 $\nabla f(x^*) = 0$ ，并且 $\nabla^2 f(x^*)$ 正定，则 x^* 是 (UMP) 的严格局部最优解。

全局最优解的充分条件

定理 4.4.4 设 $f: \mathbb{R}^n \mapsto \mathbb{R}$, $x^* \in \mathbb{R}^n$, f 是 \mathbb{R}^n 上的可微凸函数。若有 $\nabla f(x^*) = 0$, 则 x^* 是(UMP)的全局最优解。

- 证：因为 f 是 \mathbb{R}^n 上的可微凸函数，由凸函数的判别定理 4.2.3, 可知 $\forall x \in \mathbb{R}^n$, 有 $\nabla f(x^*)(x - x^*) \leq f(x) - f(x^*)$ 。
- 由于 $\nabla f(x^*) = 0$, 因此 $\forall x \in \mathbb{R}^n$, $0 \leq f(x) - f(x^*)$, 即 $f(x^*) \leq f(x)$ 。
- 因此 x^* 是(UMP)的全局最优解。

例4.4.1

例 4.4.1 求 **UMP** $\min f(x) = x_1^2 + 4x_2^2 + x_3^2 - 2x_1$ 的（全局）最优解。

- 解：先求驻点。 $f(x)$ 的梯度向量 $\nabla f(x) = (2x_1 - 2, 8x_2, 2x_3)^T$ 。
令 $\nabla f(x) = 0$ ，求得 f 的驻点 $\bar{x} = (1 \ 0 \ 0)^T$ 。
- f 的 Hesse 矩阵 $\nabla^2 f(x) = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 8 & 0 \\ 0 & 0 & 2 \end{pmatrix}$ ，正定。由定理 4.2.4， f 是（严格）凸函数。
- f 显然可微。再由定理 4.4.4， $\bar{x} = (1 \ 0 \ 0)^T$ 就是 f 的全局最优解。

最速下降法

基本思想

- 设 UMP 问题中的目标函数 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 一阶连续可微。
- 最速下降法（Cauchy, 1867）的基本思想是：从当前点 x^k 出发，沿 $f(x)$ 在 x^k 处下降最快的方向搜索下一个点 x^{k+1} ，直到当前点处函数 $f(x)$ 的“下降程度”可以忽略不计（小于等于某个给定的 $\varepsilon > 0$ ）。
- 什么是下降最快的方向？——**负梯度方向**。
- $f(x)$ 的 Taylor 展开式： $f(x + \Delta x) = f(x) + \nabla f(x)^T \Delta x + o(\|\Delta x\|)$ 。
因此， $f(x) - f(x + \Delta x) = -\nabla f(x)^T \Delta x + o(\|\Delta x\|)$ 。
忽略无穷小量 $o(\|\Delta x\|)$ ，可知 Δx 取 $-\nabla f(x)$ 方向（内积最大），函数值下降最多。

最速下降法

($\varepsilon > 0$ 为给定终止误差)

1 选取初始点 x^0 , $k \leftarrow 1$ 。

2 **while** $\|\nabla f(x^k)\| > \varepsilon$ **do**

3 $p^k \leftarrow -\nabla f(x^k)$ 。

4 一维搜索求 t_k , 使得 $f(x^k + t_k p^k) = \min_{t \geq 0} f(x^k + t p^k)$ 。

5 $x^{k+1} \leftarrow x^k + t_k p^k$, $k \leftarrow k + 1$ 。

6 **endwhile**

7 **return** x^k 。

例4.4.2

例 4.4.2 用最速下降法求解 UMP 问题

$$\min f(x_1, x_2) = x_1^2 + 25x_2^2,$$

初始点 $x^0 = (2, 2)^T$, 终止误差 $\varepsilon = 10^{-6}$ 。

解: $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix}$, $\|\nabla f(x^0)\| = \sqrt{4^2 + 100^2} \gg 10^{-6}$ 。

$$p^0 = -\nabla f(x^0) = \begin{pmatrix} -4 \\ -100 \end{pmatrix}, \quad x^0 + tp^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix} + t \begin{pmatrix} -4 \\ -100 \end{pmatrix} = \begin{pmatrix} 2 - 4t \\ 2 - 100t \end{pmatrix}。$$

$$f(x^0 + tp^0) = (2 - 4t)^2 + 25(2 - 100t)^2。$$

$$\frac{df(x^0 + tp^0)}{dt} = -8(2 - 4t) - 5000(2 - 100t)。$$

例4.4.2

令 $\frac{df(x^0 + tp^0)}{dt} = 0$ ，计算得 $t_0 = \frac{10016}{500032} \approx 0.020037$ 。

$$x^1 = x^0 + t_0 p^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix} + 0.020037 \begin{pmatrix} -4 \\ -100 \end{pmatrix} = \begin{pmatrix} 1.919878 \\ -0.003070 \end{pmatrix}。$$

k	x^k	$\nabla f(x^k)$	$\ \nabla f(x^k)\ $	p^k	t_k
0	$\begin{pmatrix} 2 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 4 \\ 100 \end{pmatrix}$	100.079968	$\begin{pmatrix} -4 \\ -100 \end{pmatrix}$	0.020037
1	$\begin{pmatrix} 1.919852 \\ -0.0037 \end{pmatrix}$	$\begin{pmatrix} 3.839704 \\ -0.185 \end{pmatrix}$	3.844158	$\begin{pmatrix} -3.839704 \\ 0.185 \end{pmatrix}$	0.486464
2	$\begin{pmatrix} 0.051974 \\ 0.086296 \end{pmatrix}$	$\begin{pmatrix} 0.103948 \\ 4.3148 \end{pmatrix}$	4.316052

经过 10 轮迭代，可得到满足误差 10^{-6} 的解。

相邻的两个搜索方向正交

- 考虑例 4.4.2 第 k 步，一维搜索时求到的 t_k 是 $f(x^k + tp^k)$ 的极

小点，因此 $\frac{df(x^k + tp^k)}{dt} = 0$ 。


- 令 $x^k + tp^k = (x_1^k + tp_1^k, x_n^k + tp_n^k, \dots, x_n^k + tp_n^k) = (u_1, u_2, \dots, u_n) = u$ ，

由复合函数求导法则，

$$\begin{aligned}\frac{df(x^k + tp^k)}{dt} &= \frac{\partial f(u)}{\partial u_1} \frac{du_1}{dt} + \frac{\partial f(u)}{\partial u_2} \frac{du_2}{dt} + \dots + \frac{\partial f(u)}{\partial u_n} \frac{du_n}{dt} \\ &= \frac{\partial f(u)}{\partial u_1} p_1^k + \frac{\partial f(u)}{\partial u_2} p_2^k + \dots + \frac{\partial f(u)}{\partial u_n} p_n^k \\ &= \nabla f(u)^T p^k \text{。}\end{aligned}$$

相邻的两个搜索方向正交

- 因此 $\nabla f(x^k + tp^k)^T p^k = 0$ 。
- 由于 $p^{k+1} = -\nabla f(x^k + tp^k)^T$ ，这表明 $p^{k+1} p^k = 0$ 。



例4.4.2的搜索路径示意图

关于最速下降法的说明

- 因此，“最速下降法”的搜索路径从整体上看是成直角锯齿状（当每个 t_k 都是极小点时）。
- 这表明最速下降法在每个 x^k 处是沿下降最快的方向搜索最优解的，但从整体上看这样做未必最快（“局部最快”不一定导致“全局最快”）。
- 最速下降法具有**全局收敛性**——无论从任何初始点 x^0 开始，所产生的点列均收敛。

共轭方向法

共轭方向

定义 4.4.1 设 A 为 n 阶实对称矩阵, 对于非零向量 $p, q \in \mathbb{R}^n$, 若有

$$p^T A q = 0,$$

则称 p 和 q 是**相互 A 共轭**的。

对于非零向量组 $p^i \in \mathbb{R}^n$, $i = 0, 1, \dots, n-1$, 若有

$$(p^i)^T A p^j = 0, \quad i, j = 0, 1, \dots, n-1, \quad i \neq j$$

则称 p^0, p^1, \dots, p^{n-1} 是 **A 共轭方向组**, 也称它们为一组 **A 共轭方向**。

二次严格凸函数的无约束最优化问题

二次严格凸函数的无约束最优化问题：

$$\min f(x) = \frac{1}{2} x^T A x + b^T x + c \quad (\text{AP})$$

其中 A 是 n 阶实对称正定矩阵， $b \in \mathbb{R}^n$ ， $c \in \mathbb{R}$ 。

定理 4.4.6 对于问题(AP)，若 p^0, p^1, \dots, p^{n-1} 为任意一组 A 共轭方向，则由任意初始点 $x^0 \in \mathbb{R}^n$ 出发，依次沿 p^0, p^1, \dots, p^{n-1} 进行精确一维搜索，则最多经 n 次迭代可达到(AP)的整体最优解。

共轭方向法 与 共轭梯度法

- 从任意点 $x^0 \in \mathbf{R}^n$ 出发，依次沿某组共轭方向进行一维搜索求解UMP的方法，叫做**共轭方向法**。
- 在共轭方向法中，若利用迭代点处的负梯度向量来产生一组共轭方向，则这样的方法叫做**共轭梯度法**。

F-R共轭梯度法

- 任取初始点 $x^0 \in \mathbb{R}^n$, $k=0$ 。一旦 $\nabla f(x^k)=0$, 则停止（表明达到了目标函数的一个驻点）。否则, 依次按下式确定第 k 次的搜索方向 p^k :
- $p^0 = -\nabla f(x^0)$
 $p^{k+1} = -\nabla f(x^{k+1}) + \lambda_k p^k$, $k=0, 1, \dots, n-2$,
其中 $\lambda_k = \frac{(p^k)^T A \nabla f(x^{k+1})}{(p^k)^T A p^k}$ 。
- 由 λ_k 的取法, 易知 p^{k+1} 和 p^k 是 A 共轭的 ($(p^{k+1})^T A p^k = 0$)。可以证明, 在这种取法下, p^{k+1} 和 p^0, p^1, \dots, p^k 也是 A 共轭的。

F-R共轭梯度法

- 任取初始点 $x^0 \in \mathbb{R}^n$, $k=0$ 。一旦 $\nabla f(x^k)=0$, 则停止 (表明达到了目标函数的一个驻点)。否则, 依次按下式确定第 k 次的搜索方向 p^k :
- $p^0 = -\nabla f(x^0)$
 $p^{k+1} = -\nabla f(x^{k+1}) + \lambda_k p^k$, $k=0, 1, \dots, n-2$,
其中 $\lambda_k = \frac{(p^k)^T A \nabla f(x^{k+1})}{(p^k)^T A p^k}$ 。
- 由 λ_k 的取法, 易知 p^{k+1} 和 p^k 是 A 共轭的 ($(p^{k+1})^T A p^k = 0$)。可以证明, 在这种取法下, p^{k+1} 和 p^0, p^1, \dots, p^k 也是 A 共轭的。

F-R共轭梯度法

- 当求解的问题是 AP 问题时，计算搜索方向的参数 λ_k 可进一

步简化为：
$$\lambda_k = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}, \quad k = 0, 1, \dots, n-2。$$

F-R共轭梯度法

[Fletcher, Reeves, 1964]

(参数 $\varepsilon > 0$ 为终止误差。)

1 选取初始点 x^0 。

2 **while** $\|\nabla f(x^0)\| > \varepsilon$ **do**

3 $p^0 \leftarrow -\nabla f(x^0)$, $k \leftarrow 0$ 。

4 **while true do**

5 一维搜索求 $t_k = \arg \min_{t \geq 0} f(x^k + tp^k)$ 。

6 $x^{k+1} \leftarrow x^k + t_k p^k$ 。

7 **if** $\|\nabla f(x^{k+1})\| \leq \varepsilon$ **then return** x^{k+1} 。

8 **if** $k + 1 = n$ **then** $x^0 \leftarrow x^n$, 退出循环。

F-R共轭梯度法

9 $\lambda_k = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}, \quad p^{k+1} \leftarrow -\nabla f(x^{k+1}) + \lambda_k p^k。$

10 $k \leftarrow k + 1。$

11 endwhile

12 endwhile

13 return $x^0。$

例4.4.4

例 4.4.4 用 F-R 共轭梯度法求解 $\min f(x_1, x_2) = x_1^2 + 25x_2^2$ 。初始点 $x^0 = (2, 2)^T$ ，终止误差 10^{-6} （仅计算到 1）。

● 解：计算结果列表如下：

k	x^k	$\nabla f(x^k)$	$\ \nabla f(x^k)\ $	p^k	t^k	λ_k
0	$\begin{pmatrix} 2 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 4 \\ 100 \end{pmatrix}$	100.079968	$\begin{pmatrix} -4 \\ -100 \end{pmatrix}$	0.020037	0.001475
1	$\begin{pmatrix} 1.919852 \\ -0.0037 \end{pmatrix}$	$\begin{pmatrix} 3.839704 \\ -0.185 \end{pmatrix}$	3.844158	$\begin{pmatrix} -3.845604 \\ 0.0375 \end{pmatrix}$	0.498283	
2	$\begin{pmatrix} 0.003653 \\ 0.014986 \end{pmatrix}$	$\begin{pmatrix} 0.007306 \\ 0.7493 \end{pmatrix}$	0.749336			

最后输出 $x = \begin{pmatrix} 0.003653 \\ 0.014986 \end{pmatrix}$ 。

例4.4.4

若干中间计算公式:

- $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix},$
- $f(x + tp) = (x_1 + tp_1)^2 + 25(x_2 + tp_2)^2,$
$$\frac{df(x + tp)}{dt} = 2(x_1 + tp_1)p_1 + 50(x_2 + tp_2)p_2$$
$$= (2p_1^2 + 50p_2^2)t + 2p_1x_1 + 50p_2x_2 \circ$$

例4.4.4

各步计算过程如下：

● $k = 0$ 。

● $x^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \quad \nabla f(x^0) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 100 \end{pmatrix}, \quad \|\nabla f(x^0)\| = 100.079968。$

● $p^0 = -\nabla f(x^0) = \begin{pmatrix} -4 \\ -100 \end{pmatrix}。$

● 解 $\frac{df}{dt} = (2p_1^2 + 50p_2^2)t + 2p_1x_1 + 50p_2x_2 = 500032t - 10016 = 0,$

得 $t_0 \approx 0.020037。$

● $x^1 = x^0 + t_0 p^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix} + \begin{pmatrix} -0.080148 \\ -2.0037 \end{pmatrix} = \begin{pmatrix} 1.919852 \\ -0.0037 \end{pmatrix}$

例4.4.4

- $\nabla f(x^1) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix} = \begin{pmatrix} 3.839704 \\ -0.185 \end{pmatrix},$

$$\|\nabla f(x_1)\| = \sqrt{3.839704^2 + (-0.185)^2} = 3.844158$$

- $\lambda^0 = \frac{\|\nabla f(x_1)\|^2}{\|\nabla f(x_0)\|^2} = \frac{3.839704^2 + (-0.185)^2}{4^2 + 100^2} = 0.001475。$

- $k = 1。$

$$p^1 = -\nabla f(x^1) + \lambda_0 p^0$$

- $= \begin{pmatrix} -3.839704 \\ 0.185 \end{pmatrix} + \begin{pmatrix} -0.0059 \\ -0.1475 \end{pmatrix} = \begin{pmatrix} -3.845604 \\ 0.0375 \end{pmatrix}。$

例4.4.4

- $\frac{df}{dt} = (2p_1^2 + 50p_2^2)t + 2p_1x_1 + 50p_2x_2 = 29.647653t - 14.772919。$

解 $\frac{df}{dt} = 0$ ，得 $t_1 = 0.498283。$

- $x^2 = x^1 + t_1 p^1 = \begin{pmatrix} 1.919852 \\ -0.0037 \end{pmatrix} + \begin{pmatrix} -1.916199 \\ 0.018686 \end{pmatrix} = \begin{pmatrix} 0.003653 \\ 0.014986 \end{pmatrix}。$

- $\nabla f(x^2) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix} = \begin{pmatrix} 0.007306 \\ 0.7493 \end{pmatrix}，$

$$\|\nabla f(x^2)\| = \sqrt{0.007306^2 + 0.7493^2} = 0.749336。$$

关于共轭梯度法的说明

- 满足一定条件时，具有全局收敛性。
- 运算简单，收敛速度快，存储量小。
- 依赖于一维精确搜索。

谢谢大家