
第4章 非线性规划

4.5 约束最优化方法

约束最优化方法

一般的数学规划问题（带约束的非线性规划问题）：

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & \begin{cases} g_i(x) \leq 0, & i = 1, \dots, p \\ h_j(x) = 0, & j = 1, \dots, q \end{cases} \end{array} \quad (\text{MP})$$

其中， $x \in \mathbb{R}^n$ ， $f, g_i, h_j : \mathbb{R}^n \mapsto \mathbb{R}$ 。

- 约束最优化问题的最优性条件
- 简约梯度法
- 惩罚函数法

1. Kuhn-Tucker条件

MP最优解的必要条件

- 记 X 为 MP 的可行域, 指标集 $I = \{1, \dots, p\}, J = \{1, \dots, q\}$ 。
- 任给一个可行点 $x \in X$, 记 $I(x) = \{i \mid g_i(x) = 0, i \in I\}$ 。即, $I(x)$ 和 J 均为取得等式约束的下标的集合。
- 称以等式 ($g_i(x) = 0$) 成立的约束 $g_i(x) \leq 0$ 为**积极约束**。

K-T条件


定理 4.5.1 (Kuhn (库恩), Tucker (塔克), 1951)

- (1) x^* 是可行域 X 中的一个点。
- (2) 设函数 f 和 g_i ($i \in I(x^*)$) 在点 x^* 处可微,
- (3) g_i ($i \in I \setminus I(x^*)$) 在点 x^* 处连续,
- (4) h_j ($j \in J$) 在点 x^* 处连续可微,
- (5) 并且各 $\nabla g_i(x^*)$, $i \in I(x^*)$, $\nabla h_j(x^*)$, $j \in J$ 线性无关。


若 x^* 是 MP 的局部最优解, 则存在两组实数 $\lambda_i^*, i \in I(x^*)$ 和

$$\mu_j^*, j \in J, \text{ 使得 } \begin{cases} \nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*) + \sum_{j \in J} \mu_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* \geq 0, \quad i \in I(x^*) \end{cases} .$$

K-T条件的解释




左图: $-\nabla f(x^*) = \lambda_1 \nabla g_1(x^*)$,
 x^* 为局部最优解。




右图: $-\nabla f(x')$ 与 $\nabla g_1(x')$ 方向
不重合, x' 还可更优。

K-T条件的解释



$-\nabla f(x^*)$ 位于 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 的夹角内（位于 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 所构成的锥内）， $-\nabla f(x^*) = \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*)$ ， x^* 为局部最优解。

K-T条件的解释



$-\nabla f(x')$ 不位于 $\nabla g_1(x')$ 和 $\nabla g_2(x')$ 所构成的锥内, x' 还可以更优。

两个概念

- MP 问题若无等式约束，则 K-T 条件简化为

$$-\nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*), \text{ 其中 } \lambda_i^* \geq 0, \forall i \in I(x^*).$$

此时称 $-\nabla f(x^*)$ 位于 $\nabla g_i(x^*), i \in I(x^*)$ 所张成的锥内。

- MP 问题若无不等式约束，则 K-T 条件简化为

$$-\nabla f(x^*) = \sum_{j \in J} \mu_j^* \nabla h_j(x^*),$$

此时称 $-\nabla f(x^*)$ 位于 $\nabla h_j(x^*), j \in J$ 所生成的子空间内。

K-T条件的变化

定理 4.5.1'

- (1) x^* 是可行域 X 中的一个点。
- (2) 设函数 f, g_i ($i \in I$), h_j ($j \in J$) 在点 x^* 处可微,
- (3) 并且各 $\nabla g_i(x^*)$, $i \in I(x^*)$, $\nabla h_j(x^*)$, $j \in J$ 线性无关。

若 x^* 是 MP 的局部最优解, 则存在两组实数 $\lambda_i^*, i \in I$ 和

$$\mu_j^*, j \in J, \text{ 使得 } \begin{cases} \nabla f(x^*) + \sum_{i \in I} \lambda_i^* \nabla g_i(x^*) + \sum_{j \in J} \mu_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, \quad i \in I \\ \lambda_i^* \geq 0, \quad i \in I \end{cases},$$

其中 $\lambda_i^* g_i(x^*) = 0$, $i \in I$ 称为**互补松紧条件**。

K-T条件的简写

记 $L(x, \lambda, \mu) = f(x) + \sum_{i \in I} \lambda_i g_i(x) + \sum_{j \in J} \mu_j h_j(x)$ ，则 **K-T** 条件可简写为：

$$\begin{cases} \nabla_x L(x^*, \lambda^*, \mu^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, \quad i \in I \\ \lambda_i^* \geq 0, \quad i \in I \end{cases},$$

其中 $\nabla_x L(x^*, \lambda^*, \mu^*)$ 表示函数 $L(x, \lambda, \mu)$ 对 x 的梯度向量在 (x^*, λ^*, μ^*) 处的值。

$L(x, \lambda, \mu)$ 称为 **Lagrange** 函数， λ ， μ 称为 **Lagrange** 乘子。

K-T条件的有限充分性

定理 4.5.2

1. 设 x^* 为 MP 问题的可行点,
 2. 函数 f, g_i, h_j 在 x^* 处连续可微, $\forall i \in I, \forall j \in J$,
 3. f, g_i 是凸函数, h_j 是线性函数, $\forall i \in I(x^*), \forall j \in J$ 。
- 若点 x^* 满足 MP 的 K-T 条件, 则 x^* 是 MP 的整体最优解。

2. 简约梯度法

处理的问题

简约梯度法（reduced gradient method）处理带有线性约束的非线性规划问题。其标准形式为：

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{array} \quad (\text{LC-MP})$$

其中， $x \in \mathbb{R}^n$ ， $f: \mathbb{R}^n \mapsto \mathbb{R}$ ， $r(A_{m \times n}) = m$ ， $b \in \mathbb{R}^m$ 。

LC-MP 的可行域记为： $X_l = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$ 。

简约梯度法的基本思想

- 将一个可行解 x^k 的前 m 个最大的正分量定义为**基变量**，其余的 $n - m$ 个变量定义为**非基变量**。（仿照 LP 的单纯形算法——但不完全相同）。
- 为此，假设（1） X_I 中的每一个可行解至少有 m 个大于零的分量；（2） A 的任意 m 列线性无关。——**非退化假设**。
- 因为可行解 x^k 满足约束 $A \begin{pmatrix} x_B^k \\ x_N^k \end{pmatrix} = b$ ， x^k 中的基变量 x_B^k 可用非基变量 x_N^k 表示。从而，目标函数 f 可写为非基变量 x_N^k 的函数。
- **基本思想**：根据这样的目标函数的负梯度方向构造可行下降方向 p^k ，沿 p^k 搜索下一个可行解 x^{k+1} 。

计算目标函数的梯度

- 按基变量的定义，可行解 $x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$ ，约束矩阵 A 也相应划分为 (B, N) 。不失一般性，假设 B 恰好由 A 的第 1 列~第 m 列组成， N 因此由第 $m+1$ 列~第 n 列组成。
- $Ax = b \Rightarrow Bx_B + Nx_N = b \Rightarrow x_B = B^{-1}b - B^{-1}Nx_N$ 。
- 因此目标函数 $f(x) = f(x_B, x_N) = f(B^{-1}b - B^{-1}Nx_N, x_N)$ ，记为 $F(x_N)$ 。
- 下面计算 $\nabla F(x_N) = \left(\frac{\partial F}{\partial x_{m+1}}(x_N), \frac{\partial F}{\partial x_{m+2}}(x_N), \dots, \frac{\partial F}{\partial x_n}(x_N) \right)^T$ 。

计算目标函数的梯度

- 为此，将 $F(x_N)$ 重写为 $F(x_N) = f(u(x_N), v(x_N))$ ，其中 $u(x_N) = B^{-1}b - B^{-1}Nx_N$ ， $v(x_N) = x_N$ 。
- 应用复合函数求导法则，有：

$$\begin{aligned} & \frac{\partial F}{\partial x_{m+1}}(x_N) \\ &= \frac{\partial f(u, v)}{\partial u_1} \frac{\partial u_1(x_N)}{\partial x_{m+1}} + \frac{\partial f(u, v)}{\partial u_2} \frac{\partial u_2(x_N)}{\partial x_{m+1}} + \dots + \frac{\partial f(u, v)}{\partial u_m} \frac{\partial u_m(x_N)}{\partial x_{m+1}} \\ & \quad + \frac{\partial f(u, v)}{\partial v_1} \frac{\partial v_1(x_N)}{\partial x_{m+1}} + \frac{\partial f(u, v)}{\partial v_2} \frac{\partial v_2(x_N)}{\partial x_{m+1}} + \dots + \frac{\partial f(u, v)}{\partial v_{n-m}} \frac{\partial v_{n-m}(x_N)}{\partial x_{m+1}} \end{aligned}$$

$$\text{其中 } \frac{\partial v_1(x_N)}{\partial x_{m+1}} = 1, \quad \frac{\partial v_2(x_N)}{\partial x_{m+1}} = 0, \quad \dots, \quad \frac{\partial v_{n-m}(x_N)}{\partial x_{m+1}} = 0。$$

计算目标函数的梯度

- 因此，梯度向量 $\nabla F(x_N)$ 可表示为：

$$\begin{pmatrix} \frac{\partial F(x_N)}{\partial x_{m+1}} \\ \frac{\partial F(x_N)}{\partial x_{m+2}} \\ \vdots \\ \frac{\partial F(x_N)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \frac{\partial u_1(x_N)}{\partial x_{m+1}} & \frac{\partial u_2(x_N)}{\partial x_{m+1}} & \dots & \frac{\partial u_m(x_N)}{\partial x_{m+1}} \\ \frac{\partial u_1(x_N)}{\partial x_{m+2}} & \frac{\partial u_2(x_N)}{\partial x_{m+2}} & \dots & \frac{\partial u_m(x_N)}{\partial x_{m+2}} \\ \vdots & \vdots & \dots & \vdots \\ \times & \times & \dots & \times \end{pmatrix} \begin{pmatrix} \frac{\partial f(u,v)}{\partial u_1} \\ \frac{\partial f(u,v)}{\partial u_2} \\ \vdots \\ \frac{\partial f(u,v)}{\partial u_m} \end{pmatrix} + \begin{pmatrix} \frac{\partial f(u,v)}{\partial v_1} \\ \frac{\partial f(u,v)}{\partial v_2} \\ \vdots \\ \frac{\partial f(u,v)}{\partial v_{n-m}} \end{pmatrix}$$

- 下面计算 $\frac{\partial u_1}{\partial x_{m+1}}(x_N)$, $\frac{\partial u_2}{\partial x_{m+1}}(x_N)$, 等项。

计算目标函数的梯度

- $u(x_N) = B^{-1}b - B^{-1}Nx_N$:

$$\begin{pmatrix} u_1(x_N) \\ u_2(x_N) \\ \vdots \\ u_m(x_N) \end{pmatrix} = \begin{pmatrix} \times \\ \times \\ \vdots \\ \times \end{pmatrix} - \begin{pmatrix} \times & \times & \cdots & \times \\ \times & \times & \cdots & \times \\ \vdots & & & \\ \times & \times & \cdots & \times \end{pmatrix} \begin{pmatrix} x_{m+1} \\ x_{m+2} \\ \vdots \\ x_n \end{pmatrix}$$

- $\Rightarrow \frac{\partial u_1}{\partial x_{m+1}}(x_N) = -(B^{-1}N)_{11}, \quad \frac{\partial u_2}{\partial x_{m+1}}(x_N) = -(B^{-1}N)_{21}, \quad \dots$

$$\frac{\partial u_1}{\partial x_{m+2}}(x_N) = -(B^{-1}N)_{12}, \quad \dots$$

计算目标函数的梯度

- 因此, $\nabla F(x_N) = -(B^{-1}N)^T \nabla_u f(u, v) + \nabla_v f(u, v)$
 $= -(B^{-1}N)^T \nabla_B f(x) + \nabla_N f(x),$

记为 r_N , 称为**简约梯度**,

其中 $\nabla_B f(x)$ 表示 f 对各基变量的偏导数组成的向量, $\nabla_N f(x)$ 表示 f 对各非基变量的偏导数组成的向量。

- 可行解 x^k 的简约梯度为 $r_N^k = -\left((B^k)^{-1} N^k\right)^T \nabla_B f(x^k) + \nabla_N f(x^k)$ 。

下面确定搜索方向 $p^k = \begin{pmatrix} p_B^k \\ p_N^k \end{pmatrix}$ 以构造下一个可行解

$x^{k+1} = x^k + t_k p^k$ 。先给出构造方法, 再证明其**可行**、**下降**。

构造搜索方向

- 为了保持新的解值 $f(x^{k+1})$ 下降, p_N^k 可取为 $-r_N^k$ 。但同时要保证 x^{k+1} 可行。因此, p_N^k 构造为:

$$p_i^k = \begin{cases} -r_i^k, & r_i^k \leq 0 \\ -x_i^k r_i^k, & r_i^k > 0, \end{cases} \quad i \in \text{index}(N^k). \quad (18a, 18b)$$

- 为了保证下一个解 x^{k+1} 可行, 必须有

$$Ax^{k+1} = Ax^k + t_k Ap^k = b, \quad \text{因此 } Ap^k = 0。$$

- $\Rightarrow B^k p_B^k + N^k p_N^k = 0, \Rightarrow p_B^k = -(B^k)^{-1} N^k p_N^k。 (19)$

搜索方向可行下降

定理 4.5.3 对于 LC-MP 问题 $\min\{f(x) \mid Ax = b, x \geq 0\}$, 设目标函数 f 可微, 基变量、非基变量、非退化假设、搜索方向按如上约定。则:

- (1) $p^k \neq 0 \Rightarrow p^k$ 是 f 在点 x^k 处的可行下降方向;
 - (2) $p^k = 0 \Rightarrow x^k$ 是 MP 问题的 K-T 点。((2) 的逆也成立。)
- 证。(1) 下一个探索点 $x^{k+1} = x^k + t_k p^k$, 其中 $t_k > 0$ 。由 p^k 的构造, 已有 $Ax^{k+1} = b$ 。下面证 $x^{k+1} \geq 0$ 。
 - $x_B^{k+1} = x_B^k + t_k p_B^k$ 。由非退化假设, $x_B^k > 0$ 。因此, 只要 t_k 取得适当小, 即有 $x_B^{k+1} > 0$ 。

搜索方向可行

- $x_N^{k+1} = x_N^k + t_k p_N^k$ 。由于 x_N^k 是非基变量，不能保证 $x_N^k > 0$ （但必有 $x_N^k \geq 0$ 😊）。令 $i \in \text{index}(N^k)$ ，分两种情况讨论：

- 若 $x_i^k = 0$ ，则

$$x_i^{k+1} = x_i^k + t_k p_i^k = t_k p_i^k = \begin{cases} -t_k r_i^k \geq 0, & r_i^k \leq 0 \\ -t_k x_i^k r_i^k = 0, & r_i^k > 0, \end{cases}$$

因此总有 $x_i^{k+1} \geq 0$ 。

- 若 $x_i^k > 0$ ，则可类比 x_B^k 的情形处理。
- 综上，对于适当选取的 t_k ， x^{k+1} 是可行解。

搜索方向下降

- 由定理 4.4.1, 只要 $\nabla f(x^k)^T p^k < 0$, 则 p^k 即是函数 f 在 x^k 处的下降方向。

- $$\begin{aligned}\nabla f(x^k)^T p^k &= \nabla_B f(x^k)^T p_B^k + \nabla_N f(x^k)^T p_N^k \\ &= \nabla_B f(x^k)^T \left(- (B^k)^{-1} N^k p_N^k \right) + \nabla_N f(x^k)^T p_N^k \\ &= \left(- \nabla_B f(x^k)^T (B^k)^{-1} N^k + \nabla_N f(x^k)^T \right) p_N^k \\ &= (r_N^k)^T p_N^k = \sum_{i \in \text{index}(N^k)} r_i^k p_i^k.\end{aligned}$$

- 而 $r_i^k p_i^k = \begin{cases} - (r_i^k)^2 \leq 0, & r_i^k \leq 0 \\ - x_i^k (r_i^k)^2 \leq 0, & r_i^k > 0, \text{ 因为 } x_i^k \geq 0. \end{cases}$

搜索方向下降

- 因为 $p^k = \begin{pmatrix} -(B^k)^{-1} N^k p_N^k & p_N^k \end{pmatrix} \neq 0$ ，因此 $p_N^k \neq 0$ 。
- 由 p_N^k 的定义，可知 p_N^k 的各项 (r_i^k (18a)，及 $-x_i^k r_i^k$ (18b)) 不全为 0。（若(18a)的各项全为 0，则必有(18b)的某项不为 0。若(18b)的各项全为 0，则必有(18a)的某项不为 0。）
- 因此 $\nabla f(x^k)^T p^k < 0$ 。
- 至此，已经证明了 p^k 既是可行方向，又是下降方向。因此 (1) 得证。

要满足的K-T条件

- (2), (\Rightarrow)。将 MP 问题重写为:

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & g_i(x) = -x_i \leq 0, \quad i = 1..n \\ & h_j(x) = a_j^T x = 0, \quad j = 1..m \end{array}, \text{ 其中 } a_j^T \text{ 为 } A \text{ 的第 } j \text{ 行。}$$

- 要证 x^k 为 K-T 点, 即要证明:

$$\begin{cases} \nabla f(x^k) + \sum \lambda_i^* \nabla g_i(x^k) + \sum \mu_j^* \nabla h_j(x^k) = 0 \\ \lambda_i^* g_i(x^k) = 0, \quad i = 1..n \\ \lambda_i^* \geq 0, \quad i = 1..n \end{cases}, \text{ 代入 MP 各项,}$$

$$\begin{cases} \nabla f(x^k) - \lambda^* + A^T \mu^* = 0 \\ (\lambda^*)^T x^k = 0 \\ \lambda^* \geq 0 \end{cases} \quad \circ$$

对K-T条件各项的解释

- $g_i(x^k) = -x_i \Rightarrow \nabla g_i(x^k) = -e_i$, 其中 $e_i = (0 \ 1 \ \dots \ 0)^T$ 为第 i 项为 1, 其余各项均为 0 的列向量。因此,

$$\sum_i \lambda_i^* \nabla g_i(x^k) = -\sum_i e_i \lambda_i^* = -I \lambda^* = -\lambda^*。$$

- $g_i(x^k) = -x_i \Rightarrow \lambda_i^* g_i(x^k) = -\lambda_i^* x_i$ 。

- $h_j(x^k) = a_j^T x^k \Rightarrow \nabla h_j(x^k) = a_j$ 。于是,

$$\sum_j \mu_j^* \nabla h_j(x^k) = \sum_j a_j \mu_j^* = (a_1 \quad a_2 \quad \dots \quad a_m) \begin{pmatrix} \mu_1^* \\ \mu_2^* \\ \vdots \\ \mu_m^* \end{pmatrix} = A^T \mu^*。$$

要满足的K-T条件

● 按照 $x^k = \begin{pmatrix} x_B^k \\ x_N^k \end{pmatrix}$ 的划分, 重新表示 $\lambda^* = \begin{pmatrix} \lambda_B^* \\ \lambda_N^* \end{pmatrix}$, $\mu^* = \begin{pmatrix} \mu_B^* \\ \mu_N^* \end{pmatrix}$ 。

● 于是 x^k 要满足的 K-T 条件可重写为:

$$\nabla_B f(x^k) - \lambda_B^* + (B^k)^T \mu^* = 0, \quad (1)$$

$$\nabla_N f(x^k) - \lambda_N^* + (N^k)^T \mu^* = 0, \quad (2)$$

$$(\lambda_B^*)^T x_B^k = 0, \quad (3)$$

$$(\lambda_N^*)^T x_N^k = 0, \quad (4)$$

$$\lambda_B^* \geq 0, \quad (5)$$

$$\lambda_N^* \geq 0. \quad (6)$$

x^k 满足K-T条件

- 由已知, $p^k = 0$ 。于是 $p_N^k = 0$ 。
- 由(18a), $\forall i \in \text{index}(N^k)$, 当 $r_i^k \leq 0$ 时 $p_i^k = -r_i^k$ 。 $p_N^k = 0$ 表明 r_i^k 不能严格小于 0。因此有 $r_N^k \geq 0$ 。 (7)
- 由 p_N^k 的定义 (18a, 18b), $p_N^k = 0$ 表明 $\forall i \in \text{index}(N^k)$, 或者 $r_i^k = 0$, 或者 $x_i^k r_i^k = 0$, 二者必居其一。因此,
 $(r_N^k)^T x_N^k = 0$ 。 (8)
- 定义 $\lambda_B^* = 0$, $\lambda_N^* = r_N^k$, $\mu^* = -B^{k,T,-1} \nabla_B f(x^k)$, (9a, 9b, 9c)
其中 $B^{k,T,-1} = \left((B^k)^T \right)^{-1}$ 。
- (9a) \Rightarrow (3), (9b), (8) \Rightarrow (4), (9a) \Rightarrow (5), (9b), (7) \Rightarrow (6)。

x^k 满足K-T条件

- 由(9a)和(9c), 可知

$$\begin{aligned}\nabla_B f(x^k) - \lambda_B^* + (B^k)^T \mu^* &= \nabla_B f(x^k) + (B^k)^T (-B^{k,T,-1} \nabla_B f(x^k)) \\ &= \nabla_B f(x^k) - \nabla_B f(x^k) = 0, \quad (1) \text{成立}.\end{aligned}$$

- 由(9a), (9c), 以及 r_N^k 的定义,

$$\begin{aligned}\nabla_N f(x^k) - \lambda_N^* + (N^k)^T \mu^* &= \nabla_N f(x^k) - \left[- \left((B^k)^{-1} N^k \right)^T \nabla_B f(x^k) + \nabla_N f(x^k) \right] + (N^k)^T (-B^{k,T,-1} \nabla_B f(x^k)) \\ &= \nabla_N f(x^k) + (N^k)^T B^{k,-1,T} \nabla_B f(x^k) - \nabla_N f(x^k) - (N^k)^T B^{k,T,-1} \nabla_B f(x^k) \\ &= 0, \quad (2) \text{成立}.\end{aligned}$$

- 综上, 可知 x^k 满足 K-T 条件。
- 类似的证明, 可知(2)的(\Leftarrow)成立。

确定 t_k 的上界 t_k^{\max}

- 由定理 4.5.3 的证明, $t_k > 0$ 要取为适当小的一个数。问题:
 t_k 需要小到什么界以内?
- 由新的探索点 x^{k+1} 的定义, 有 $x_i^{k+1} = x_i^k + t_k p_i^k$, $i = 1..n$ 。
- t_k 的选择要保证 $x_i^{k+1} \geq 0$ 。
- 对于 $p_i^k \geq 0$ 的 i , 则由 $x_i^k \geq 0$, $t_k \geq 0$, 已有 $x_i^{k+1} \geq 0$ 。
- 对于 $p_i^k < 0$ 的 i , 应要求 $t_k \leq -\frac{x_i^k}{p_i^k}$ 。
- 综上,
$$t_k^{\max} = \begin{cases} +\infty, & p^k \geq 0 \\ \min\left\{-\frac{x_i^k}{p_i^k} \mid p_i^k < 0, i = 1..n\right\}, & \text{存在 } p_i^k < 0. \end{cases}$$

Wolfe简约梯度法

(参数 $\varepsilon > 0$ 为终止误差。)

- 1 选取初始可行点 x^0 , $k \leftarrow 0$ 。
- 2 while true do
- 3 定义 x^k 的前 m 个最大分量的基变量。
- 4 计算简约梯度 r_N^k 。
- 5 按(18)(19)式构造可行下降方向 p^k 。
- 6 if $|p^k| \leq \varepsilon$ then 停止迭代, 退出循环。
- 7 (一维搜索) 求解 $\min_{0 \leq t \leq t_k^{\max}} f(x^k + tp^k)$, 得到 t_k 。
- 8 $x^{k+1} \leftarrow x^k + t_k p^k$, $k \leftarrow k + 1$ 。
- 9 endwhile
- 10 return x^k 。

Wolfe简约梯度法

- 例4.5.2 用Wolfe法求解约束极小化问题

$$\begin{cases} \min & x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2 \\ \text{s.t.} & x_1 + x_2 \leq 4 \\ & -x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{cases}$$

$$\text{取 } x^0 = (1, 1)^T, \varepsilon = 10^{-6}$$

解 首先将问题化为如下的问题:

$$\begin{cases} \min & x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2, \\ \text{s.t.} & x_1 + x_2 + x_3 = 4, \\ & -x_1 + x_2 + x_4 = 2, \\ & x_j \geq 0, \quad j = 1, 2, 3, 4 \end{cases}$$

取 $x^0 = (1, 1, 2, 2)^T$, $\varepsilon = 10^{-6}$. \leftarrow

Wolfe简约梯度法

第 1 轮迭代. 对于 $x^0 = (1,1,2,2)^T$, 有 $I_B^0 = \{3,4\}$, 故矩阵 \leftarrow

$$A = \begin{pmatrix} 1 & 1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{pmatrix} \leftarrow$$

相应分解为 \leftarrow

$$B_0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad N_0 = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \leftarrow$$

因为 $\nabla f(x) = (2x_1 + 2x_2 + 2, 2x_2 + 2x_1 + 6, 0, 0)^T \leftarrow$

所以 $\nabla f(x^0) = (6, 10, 0, 0)^T$. 据此可求得 x^0 点的简约梯度 \leftarrow

$$\begin{aligned} r_N^0 &= -(B_0^{-1} N_0)^T \nabla_B f(x^0) + \nabla_N f(x^0) \leftarrow \\ &= - \left[\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \right]^T \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 6 \\ 10 \end{pmatrix} = \begin{pmatrix} 6 \\ 10 \end{pmatrix} \leftarrow \end{aligned}$$

\leftarrow

Wolfe简约梯度法

有

$$p_N^0 = \begin{pmatrix} -6 \\ -10 \end{pmatrix}, p_B^0 = -B_0^{-1}N_0p_N^0 = -\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} -6 \\ -10 \end{pmatrix} = \begin{pmatrix} 16 \\ 4 \end{pmatrix}$$

因此得到可行下降方向 $p^0 = (-6, -10, 16, 4)^T$

由于 $\|p^0\| \neq 10^{-6}$, 要沿 p^0 进行有效一维搜索. 并确定

$$t_{max}^0 = \min \left\{ \frac{1}{6}, \frac{1}{10} \right\} = \frac{1}{10}$$

求解 $\min_{0 \leq t \leq \frac{1}{10}} f(x^0 + t_0 p^0) = 256t^2 - 136t + 12$

得到最优解 $t_0 = \frac{1}{10}$, 于是得到下一个迭代点

$$\begin{aligned} x^1 &= x^0 + t_0 p^0 = (1, 1, 2, 2)^T + \frac{1}{10} (-6, -10, 16, 4)^T \\ &= \left(\frac{2}{5}, 0, \frac{18}{5}, \frac{12}{5} \right)^T \end{aligned}$$

Wolfe简约梯度法

第2轮迭代. 对于 \mathbf{x}^1 , 有 $I_B^1 = \{3,4\}$. 故对矩阵A的分解仍有 \leftarrow

$$B_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad N_1 = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \leftarrow$$

由 $\nabla f(\mathbf{x}^1) = (\frac{14}{5}, \frac{34}{5}, 0, 0)^T$, 得到简约梯度 \leftarrow

$$\begin{aligned} \mathbf{r}_N^1 &= -(B_1^{-1} N_1)^T \nabla_B f(\mathbf{x}^1) + \nabla_N f(\mathbf{x}^1) \leftarrow \\ &= -\left[\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \right]^T \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \frac{14}{5} \\ \frac{34}{5} \\ \frac{34}{5} \\ \frac{14}{5} \end{pmatrix} = \begin{pmatrix} \frac{14}{5} \\ \frac{34}{5} \\ \frac{34}{5} \\ \frac{14}{5} \end{pmatrix} \leftarrow \end{aligned}$$

又有 \leftarrow

$$\mathbf{p}_N^1 = \begin{pmatrix} -\frac{28}{25} \\ \frac{28}{25} \\ 0 \end{pmatrix}, \quad \mathbf{p}_B^1 = -B_1^{-1} N_1 \mathbf{p}_N^1 = \begin{pmatrix} \frac{28}{25} \\ \frac{28}{25} \\ -\frac{28}{25} \\ \frac{28}{25} \end{pmatrix} \leftarrow$$

Wolfe简约梯度法

所以可行下降方向为 $p^1 = (-\frac{28}{25}, 0, \frac{28}{25}, -\frac{28}{25})^T$

由于 $\|p^1\| \leq 10^{-6}$, 为计算简便, 不妨重取 p^1 为

$$p^1 = (-1, 0, 1, -1)^T$$

并有

$$t_{max}^1 = \min \left\{ \frac{2}{5}, \frac{12}{5} \right\} = \frac{2}{5}$$

求解 $\min_{0 \leq t \leq \frac{2}{5}} f(x^1 + tp^1) = (\frac{2}{5} - t)^2 + 2(\frac{2}{5} - t)$

求得 $t_1 = \frac{2}{5}$, 所以

$$\begin{aligned} x^2 &= x^1 + t_1 p^1 = (\frac{2}{5}, 0, \frac{18}{5}, \frac{12}{5})^T + \frac{2}{5}(-1, 0, 1, -1)^T \\ &= (0, 0, 4, 2)^T \end{aligned}$$

Wolfe简约梯度法

第3轮迭代. 对于 \mathbf{x}^2 , 有 $I_B^2 = \{3,4\}$. 故对矩阵A的分解仍为

$$B_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad N_2 = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$$

因为 $\nabla f(\mathbf{x}^2) = (2, 6, 0, 0)^T$, 由公式求得 $\mathbf{r}_N^2 = \begin{pmatrix} 2 \\ 6 \end{pmatrix}$, 并求得

$\mathbf{p}_N^2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \mathbf{p}_B^2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$. 因而有

$$\mathbf{p}^2 = (0, 0, 0, 0)^T$$

$\|\mathbf{p}^2\| = 0 < 10^{-6}$. 由定理知 $\mathbf{x}^2 = (0, 0, 4, 2)^T$ 为初始问题的K-T点. 显然是一个凸规划, 因此所求得的 \mathbf{x}^2 为其整体最优解. 原问题的整体最优解为 $\mathbf{x}^* = (0, 0)^T$.

谢谢大家